Implementación y agregación de segmentadores

1. Integrantes del grupo

Este trabajo pertenece al Grupo 18 - Equipo 3. Los integrantes somos:

- Irene Fanjul i Penella
- Miguel Jiménez Gomis
- Carles Serra Vendrell
- Adrián Bañuls Arias
- Miriam Pardo Cuesta

Enlace a Google Colaboratory: https://colab.research.google.com/drive/1I7sQRmyx9-ks8E7igUie067lKDGkNXow?usp=sharing#scrollTo=GCFdKnFBXbUV

2. Organización de las reuniones

Reuniones	Descripción
14/02/2021	Planificación de las tareas a realizar. Elección del segmentador a desarrollar.
18/02/2021	Puesta en común de las soluciones investigadas de forma independiente por cada integrante y de las dudas surgidas.
23/02/2021	Corrección de bugs y análisis de los resultados.
24/02/2021	Redacción final de la entrega y limpieza del notebook.

Todos los integrantes del grupo han participado en todas las reuniones.

3. Descripción del problema

Como problema a tratar en este trabajo se ha seleccionado la detección de barcos en imágenes satélite. Se han escogido un subset de imágenes del Dataset de la competición de Kaggle de Airbus [2], la cual incluye el Ground truth de las imágenes para poder evaluar los resultados obtenidos.

4. Solución propuesta

Se han implementado 3 segmentadores de imágenes que generan máscaras binarias indicando las posiciones en las que puede haber un barco. Así mismo, se ha implementado un cuarto segmentador que combina las salidas de los 3 anteriormente mencionados agregando sus resultados y codificando un método de selección en caso de empate.

Se importan las librerías necesarias y se cargan los datos de prueba. Por falta de espacio no se muestran en este documento, se pueden ver en el Notebook entregado o en el enlace de Google Colab proporcionado

Importación de librerías

[ ] ↳ *2 celdas ocultas*

Programación de los segmentadores

Antes de programar los Segmentadores se definen las variables comunes y el métodod de evaluación de estos segmentadores para ello primero se genera la función que decodifica el ground truth del dataset.

```
# Decodificación del ground truth
def decodeGroundTruth(encoded_pixel, img_size, archive_name):
    encoded_pixel[0].split(' ')
    rle = list(map(int, encoded_pixel[0].split(' ')))
    pixel,pixel_count = [],[]
    [pixel.append(rle[i]) if i%2==0 else pixel_count.append(rle[i]) for i in range(0, len(rle))]
    rle_pixels = [list(range(pixel[i],pixel[i]+pixel_count[i])) for i in range(0, len(pixel))]
    rle_mask_pixels = sum(rle_pixels,[])
    mask_img = np.zeros((img_size[0]*img_size[1],1), dtype=int)
    mask_img[rle_mask_pixels] = 255
    l,b=cv2.imread(archive_name).shape[0], cv2.imread(archive_name).shape[1]
    mask = np.reshape(mask_img, (b, l)).T
```

```
    #plt.imshow(mask, cmap='gray')
    return mask/255
```

Una vez se tiene esta función para generar la máscara del ground truth, se procede a desarrollar una función para evaluar los segmentadores. Esta funcion tiene 2 partes:

- Unbucle que itera por todas las imágenes del conjunto de test y calcula su máscara del segmentador y decodifica su ground truth.
- Una función que dada la máscara y el ground truth calcula la matriz de confusión para cada imagen.

Por ultimo los resultados se agregan y se muestra el promedio de la matriz de confusión.

```
def calculate_conf_matrix(mask, ground_Truth):
  '''Esta función calcula los datos de la matriz de confusión para una máscara
  generada por un segmentador y su ground truth.
  '''
  height, width = mask.shape
  tp, fp, tn, fn = 0, 0, 0, 0
  for i in range(height):
      for j in range(width):
          if (int(mask[i,j] > 0) and (ground_Truth[i,j] > 0)):
              tp += 1
          elif (int(mask[i,j] > 0) and  (ground_Truth[i,j] == 0)):
              fp += 1
          elif (int(mask[i,j] == 0) and  (ground_Truth[i,j] == 0)):
              tn += 1
          elif (int(mask[i,j] == 0) and  (ground_Truth[i,j] > 0)):
              fn += 1
  return tp, fp, tn, fn

def test_segmentator(segmentator):
  ''' Esta funcion itera por todas las imágenes y calcula el promedio de sus matrices de confusión
  y muestra las métricas relevantes para un segmentador pasado como parámetro
  '''
  ground_Truth_Data = pd.read_csv("groundtruth.csv") #Se cargan los datos
  tp, fp, tn, fn, esp, acc, rec = [], [], [], [], [], [], []
  n = 0
  for row in ground_Truth_Data.iterrows():
    imageName = row[1][0]
    img_ = io.imread(imageName)
    GT = decodeGroundTruth([row[1][1]], img_.shape, imageName) # Se decodifica el Ground truth
    mask = segmentator(img_) #Se obtiene la máscara
    result = calculate_conf_matrix(mask, GT)
    debug = False
    if debug:
      fig, (ax1,ax2,ax3) = plt.subplots(1,3);      fig.set_size_inches(10,10)
      ax1.imshow(img_);      ax1.set_title("Imagen Original")
      ax1.axis('off');      ax2.imshow(GT, cmap='gray')
      ax2.set_title("Ground Truth");      ax2.axis('off')
      ax3.imshow(mask, cmap='gray');      ax3.set_title('Segementador')
      ax3.axis('off');      plt.show();
    tp.append(result[0]);    fp.append(result[1])
    tn.append(result[2]);    fn.append(result[3])
    esp.append(tn[n]/(tn[n]+fp[n])) if tn[n] + fp[n] != 0 else esp.append(0.00)
    acc.append(tp[n]/(tp[n]+fp[n])) if tp[n] + fp[n] != 0 else acc.append(0.00)
    rec.append(tp[n]/(tp[n]+fn[n])) if tp[n] + fn[n] != 0 else rec.append(0.00)
    if debug:
      print(f"{imageName} Recall: {rec[n]:.2f} Especificidad: {esp[n]:.2f} Precisión: {acc[n]:.2f}")
    n += 1

  print("Promedio de las métricas:")
  print("TP: ",np.sum(tp)/n, " FP: ", np.sum(fp)/n, "\nTN: ", np.sum(tn)/n, " FN: ", np.sum(fn)/n)
  print("Especificidad: ",np.sum(esp)/n, " Precision: ", np.sum(acc)/n, "Recall: ", np.sum(rec)/n)
```

Segmentador Kmeans

El algoritmo consiste en asignar cada uno de los n ejemplos uno de los k clusters, donde k es un número definido previamente. El objetivo es minimizar las diferencias entre los grupos de cada cluster y maximizar las diferencias entre clusters. El algoritmo utiliza un proceso heurístico para calcular la solución óptima.

```
def apply_kmeans(image, K):
```

```
    image=cv2.cvtColor(image,cv2.COLOR_BGR2HSV)
    vectorized = image.reshape((-1,3))
    vectorized = np.float32(vectorized)
    criteria = (cv2.TERM_CRITERIA_EPS + cv2.TERM_CRITERIA_MAX_ITER, 10, 1.0)
    attempts=10
    ret,label,center = cv2.kmeans(vectorized,K,None,criteria,attempts,cv2.KMEANS_PP_CENTERS)
    center = np.uint8(center)
    res = center[label.flatten()]
    result_image = res.reshape((image.shape))
    return result_image

def kmeans_segmentator(img):
  kmeans = apply_kmeans(img, 10)
  kmeans_gray = cv2.cvtColor(kmeans, cv2.COLOR_BGR2GRAY)
  imagen_gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
  kmeans_mask = np.where(kmeans_gray > 70, 0, 255)
  return kmeans_mask/255

image1='ejemplo_2.jpeg'
img1 = io.imread(image1)
image2='ejemplo_1.jpeg'
img2 = io.imread(image2)

kmeans_mask = kmeans_segmentator(img1)
en_pix2 = ['518036 2 518800 6 519565 10 520331 12 521099 12 521868 12 522636 12 523404 12 524172 13 524941 12 525709 12 52
ground_Truth = decodeGroundTruth(en_pix2, img1.shape, image1)
kmeans_mask1 = kmeans_segmentator(img2)
en_pix1 = ['308744 1 309511 4 310279 6 311046 9 311814 11 312581 14 313349 16 314116 19 314884 21 315651 24 316419 26 3171
ground_Truth1 = decodeGroundTruth(en_pix1, img2.shape, image2)

def mostrar(imagen, mask1, mask2, titulo_segmentador):
  fig, (ax1,ax2,ax3) = plt.subplots(1,3)
  fig.set_size_inches(10,10)
  ax1.imshow(imagen)
  ax1.set_title("Imagen Original")
  ax1.axis('off')
  ax2.imshow(mask1, cmap='gray')
  ax2.set_title("Ground Truth")
  ax2.axis('off')
  ax3.imshow(mask2, cmap='gray')
  ax3.set_title(titulo_segmentador)
  ax3.axis('off')
  plt.show();

mostrar(img1, ground_Truth, kmeans_mask, "Segmentador K means")
mostrar(img2, ground_Truth1, kmeans_mask1, "Segmentador K means")

```

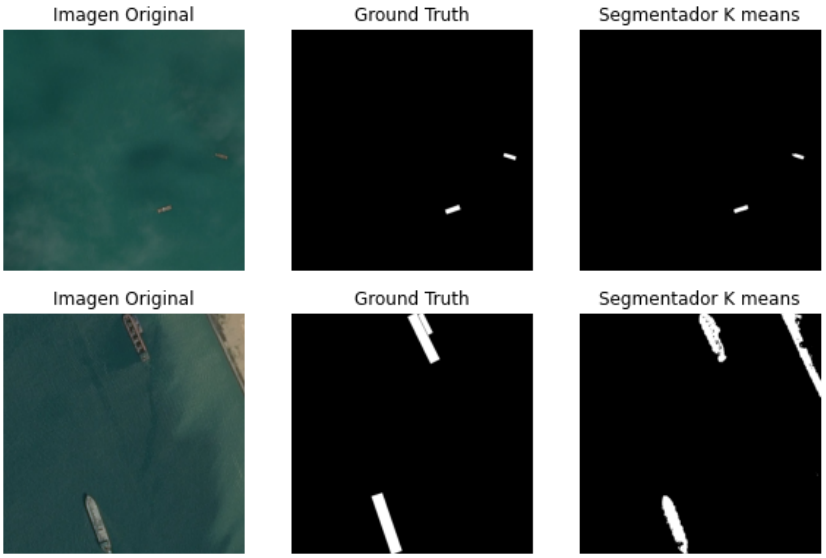

Se evalúa el segmentador generado:

```
test_segmentator(kmeans_segmentator)
```

```
Promedio de las métricas:
TP:  1857.1857142857143  FP:  104277.57142857143
TN:  480378.9285714286  FN:  3310.3142857142857
Especificidad:  0.8216580200813163  Precision:  0.41391692981282135 Recall:  0.4090340873861649
```

Segmentador Canny

El segmentador Canny es un segmentador bastante simple y computacionalmente menos costoso que los otros dos segmentadores propuestos. Inicialmente hace un suavizado de la imagen y, sobre la imagen suavizada, detecta los bordes utilizando Canny. Finalmente, se aplica una dilatación para rellenar los objetos, seguida de una erosión para reducir los contornos.

```
def canny_segmentator(img):
  blur = cv2.medianBlur(np.array(img, dtype = 'uint8'), 3)
  img1_gray = cv2.cvtColor(blur,cv2.COLOR_BGR2GRAY)# Imagen en blanco y negro
  canny = cv2.Canny(img1_gray,60,250)  # Detección de bordes con Canny
  img1_dilat = dilation(canny, disk(6))  # Dilatación
  img1_erod = erosion(img1_dilat, disk(2)) # Erosión
  return np.where(img1_erod == 0, 0, 255)/255 #Se retorna la máscara

canny_mask = canny_segmentator(img1)
canny_mask2 = canny_segmentator(img2)

mostrar(img1, ground_Truth, canny_mask, "Segmentador Canny")
mostrar(img2, ground_Truth1, canny_mask2, "Segmentador Canny")
```

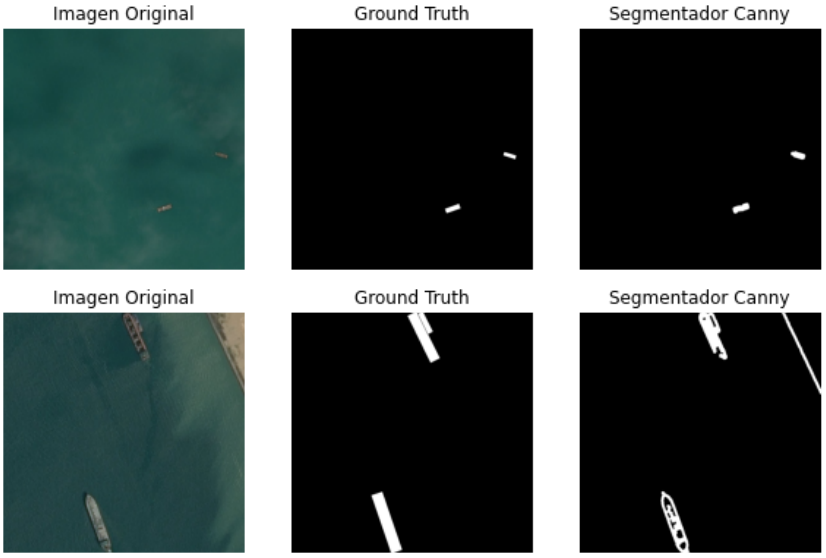

Se evalúa el segmentador generado:

```
test_segmentator(canny_segmentator)
```

```
Promedio de las métricas:
TP:  3834.157142857143  FP:  85466.4
TN:  499190.1  FN:  1333.3428571428572
Especificidad:  0.853640121980766  Precision:  0.4932145242967803 Recall:  0.7687998514158321
```

Segmentador felzenszwalb

Este segmentador produce una sobresegmentación de la imagen usando un rápido y mínimo agrupamiento basado en árboles de expansión. En cuánto a los parámetros de la función, la magnitud de scale determina la configuración de los segmentos, es decir, un valor alto de esta variable implica que el número de segmentos será menor pero estos tendrán un tamaño mayor. Por otro lado, sigma indica el tamaño del kernel Gaussiano que se utiliza para suavizar la imagen de entrada, y min_size determina el tamaño mínimo que pueden alcanzar las regiones. Los valores de estos parámetros se han obtenido de forma empírica, comprobando que se adaptan correctamente a la mayoría de las imágenes escogidas.

```
def felzenszwalb_segmentator(img):
  segments_fz = felzenszwalb(img, scale=400, sigma=4, min_size=400)
  img_fel_1 = color.label2rgb(segments_fz, img, kind='avg', bg_label=0, bg_color=0)
  img_fel_1[img_fel_1 > 0] = 255
```

```
  img_fel_1[img_fel_1 > 0] = 255
  temp = np.where(img_fel_1 == 0, 0, 255)/255
  new = np.zeros((temp.shape[0],temp.shape[1]))
  for i in range(temp.shape[0]): #Se eliminan las capas que no nos interesan
    for j in range(temp.shape[1]):
      new[i][j] = temp[i][j][0]
  return new

felzenszwalb_mask = felzenszwalb_segmentator(img1)
felzenszwalb_mask2 = felzenszwalb_segmentator(img2)

mostrar(img1, ground_Truth, felzenszwalb_mask, "Segmentador Felzenszwalb")
mostrar(img2, ground_Truth1, felzenszwalb_mask2, "Segmentador Felzenszwalb")
```

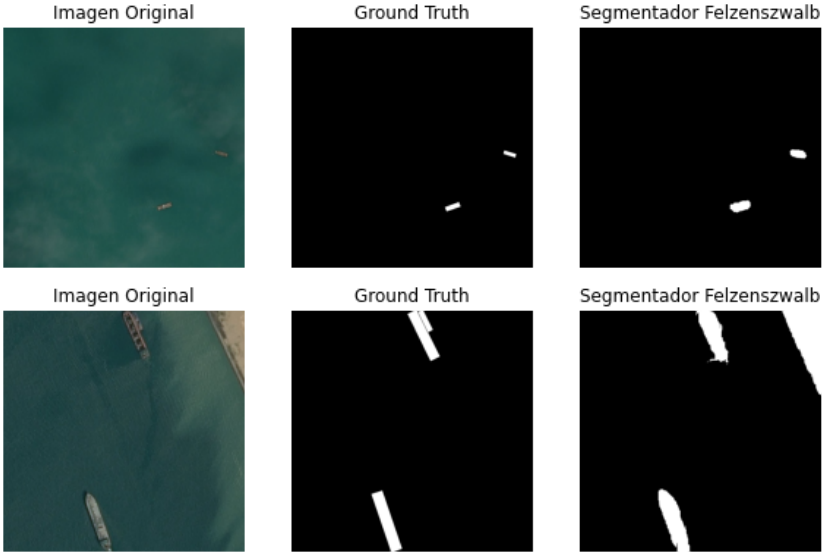

Se evalúa el segmentador generado:

```
test_segmentator(felzenszwalb_segmentator)
```

```
Promedio de las métricas:
TP:  5041.142857142857  FP:  21405.64285714286
TN:  563250.8571428572  FN:  126.35714285714286
Especificidad:  0.9635313199131909  Precision:  0.4669846752219528 Recall:  0.9678265276759055
```

Segmentador Agredado

Este segmentador funciona agregando los resultados de las máscaras binarias obtenidas por otros segmentadores. El método por el que se realiza esta agregación es por medio de un sistema de vitación en el que hay 3 posibles situaciones:

- Hay un empate en la votación de los segmentadores y por tanto se elige la selección del mejor
- Consenso en votación positiva
- Consenso en votación negativa

Esta agregación genera, como los otros segmentadores, una máscara binaria.

```
def segmerter_agregado(image):
    n, m, dummy = image.shape
    seg1_mask = kmeans_segmentator(image)
    seg2_mask = canny_segmentator(image)
    seg3_mask = felzenszwalb_segmentator(image)
    output = np.zeros((n,m))
    for i in range(n):
        for j in range(m):
            mask_sum = seg1_mask[i][j] + seg2_mask[i][j] + seg3_mask[i][j]
            if  mask_sum == 1.5:
                output[i][j] = seg1_mask[i][j] # Si hay mismo número de barcos que no barcos se selecciona el mejor segmer
            elif mask_sum < 1.5:
                output[i][j] = 0 # Si hay menos de 2 que seleccionen barco es mar
            else:
                output[i][j] = 1 #Si hay mas de 2 que son barco es barco
    return output
```

```
    return output

agregado_mask = segmerter_agregado( img1)
agregado_mask2 = segmerter_agregado( img2)
mostrar(img1, ground_Truth, agregado_mask, "Segmentador agregado")
mostrar(img2, ground_Truth1, agregado_mask2, "Segmentador agregado")
```

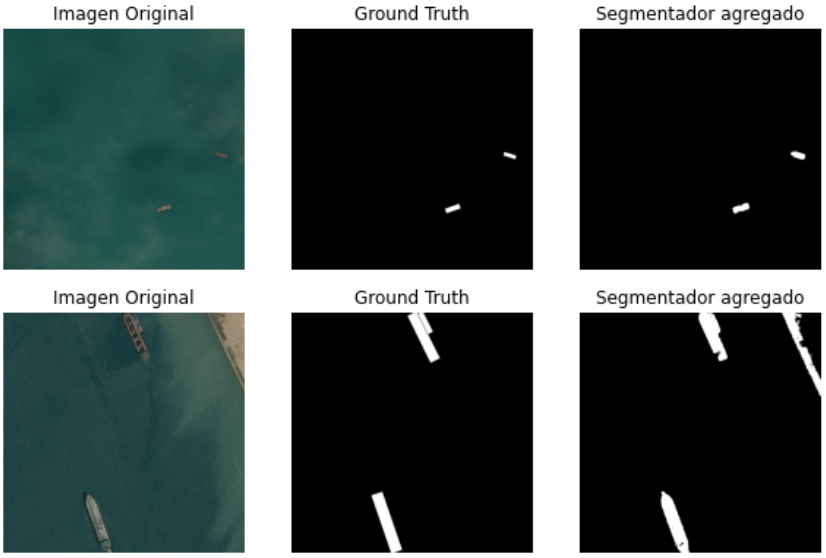

Se evalúa el segmentador generado:

```
test_segmentator(segmerter_agregado)
```

```
Promedio de las métricas:
TP:  4147.1  FP:  65460.0
TN:  519196.5  FN:  1020.4
Especificidad:  0.8879256033321499  Precision:  0.5472948549210893 Recall:  0.8428666390778291
```

Resultados

A continuación se muestran los promedios de las métricas calculadas para los diferentes segmentadores desarrollados:

	Kmeans	Canny	Felzenszwalb	Agregado
Especificidad	0.8216	0.8536	0.9635	0.8879
Precisión	0.4139	0.4932	0.4669	0.5472
Recall	0.4090	0.7687	0.9678	0.8428

**Si se desea visualizar todas las imágenes del dataset y su resultado se debe modificar la variable "debug" en la función test_segmentador*

Conclusiones

Como se puede observar el segmentador agregado mejora la precisión a costa de una menor especificidad y Recall que el mejor segmentador obtenido (Felzenszwalb). El agregado se muestra ligeramente más robusto frente a imágenes con mucho ruido, ya sea de nubes o de oleaje.

El hecho de que se hayan usado los mismos parámetros de entrada para todas las imágenes hace que los resultados obtenidos empeoren, pero debido a la complejidad de automatizar la selección de parámetros para cada imágen se ha optado por no implementarlo.

También cabe destacar que el ground truth de este dataset no se ajusta a la silueta de los barcos a identificar, sino que señala el área rectangular donde estos se encuentran, empeorando asi las métricas de los segmentadores puesto que las máscaras generadas si se ajustan a esta silueta.

7. Bibliografía

[1] 19/02/2021, https://medium.com/analytics-vidhya/generating-masks-from-encoded-pixels-semantic-segmentation-18635e834ad0

[2] 19/02/2021, https://www.kaggle.com/c/airbus-ship-detection/overview